

# Trabajo práctico 3

IECD323: Estadística Bayesiana

*Bastían Barraza Morales*

December 15, 2022

---

## Introducción

Al realizar un análisis estadístico desde un enfoque Bayesiano, se busca incorporar las creencias y la información a priori que uno tiene acerca de un evento aleatorio en una muestra (aleatoria), y de este modo, producir una distribución a posteriori con la información actualizada. El cálculo de una distribución a posteriori no siempre es fácil de obtener analíticamente, y en muchos casos es imposible, por lo que muchos autores han buscado métodos alternativos (principalmente computacionales) para definir o aproximar esta distribución.

El muestreo Gibbs (Gibbs sampling) es un método MCMC (Markov Chain Monte Carlo), el cual permite aproximar la distribución a posteriori conjunta  $\pi(\theta_1, \theta_2, \dots, \theta_n | \vec{X})$ , cuando cada una de las distribuciones condicionales  $\pi(\theta_i | \theta_j, \dots, \theta_n | \vec{X})$  con  $i \neq j$  son especificadas o simples de encontrar. Esto se realiza asumiendo que existe una distribución estacionaria, la cual se aproximará a la distribución a posterior de los parámetros dada una muestra aleatoria.

Este documento tiene como objetivo aproximar la distribución a posteriori mediante el método de Gibbs Sampling con los datos de una muestra aleatoria simulada y la distribución a priori de los parámetros.

Para el presente informe se utilizará el software R para realizar las simulaciones, gráficos y cálculos necesarios.

## 1 Ejercicio 1:


Simular  $x_1, x_2, \dots, x_{50} | (\theta = 5, \sigma^2 = \phi^{-1} = 2) \sim N(5, 2)$ .

Respuesta:

Al realizar la simulación de 50 valores con los valores dados (Apéndice A.1) se obtienen las siguientes estadísticas descriptivas de X.

Mínimo	Cuartil 1	Mediana	Media	Cuartil 4	Máximo	Varianza
2.75	4	4.887	5.032	5.806	7.956	1.68

Se observan que el cuartil 1 y cuartil 4 están casia la misma distancia de la media al igual que el valor mínimo y máximo. Por otro lado, en la figura 1 se observa el histograma de la distribución de probabilidad de X en donde la media está dibujada con una recta azul (Apéndice B.1).



**Figure 1:** Distribución de probabilidad de X.

## 2 Ejercicio 2

Considerar  $\pi(\theta) \sim N(0, \tau_0^2)$  y  $\pi(\phi) \sim \text{Gamma}(\frac{a_0}{2}, \frac{b_0}{2})$ , donde  $a_0 = n_0 = 10$  y  $b_0 = n_0\sigma_0^2 = 25$

Respuesta:

Dado que  $X \sim N(5, 2)$  y con las distribuciones a priori de  $\theta$  y  $\phi$  se puede especificar completamente  $\pi(\theta, \phi|X)$  mediante una constante de normalización de la expresión:

$$\pi(\theta, \phi|X) \propto \pi(\theta, \phi) \pi(\theta) \pi(\phi)$$

Sin embargo, esta constante de normalización resulta imposible de calcular analíticamente. Ahora bien, si se puede obtener las densidades condicionales a posteriori  $\pi(\theta|\phi, X)$  y  $\pi(\phi|\theta, X)$ . En efecto:

$$\pi(\theta|\phi, X) \sim N\left(\frac{\tau_0^{-2}\mu_0 + n\phi\bar{x}_n}{\tau_0^{-2} + n\phi}, (\tau_0^{-2} + n\phi)^{-1}\right)$$
$$\pi(\phi|\theta, X) \sim \text{Gamma}\left(\frac{n + n_0}{2}, (b_0 + (n - 1)S^2 + n(\theta - \bar{X}_n)^2)^{-2}\right)$$

Con las densidades condicionales a posteriori se pueden aplicar el método de Gibbs sampling para aproximar la distribución a posteriori conjunta.

### 3 Ejercicio 3


Simule 1000 iteraciones usando 'Gibbs Sampling'.

Respuesta:


Para realizar el método Gibbs Sampling se consideran los valores iniciales de  $\theta^{(0)}$  y  $\phi^{(0)}$  desde  $\pi(\theta|\phi^{(0)}, X)$  y  $\pi(\phi|\theta^{(0)}, X)$  respectivamente.

Luego, a partir de estas cantidades iniciales, se simulan los valores de  $\theta^{(i)}$  y  $\phi^{(i)}$  con  $i = 1, 2, \dots, n$  en donde se considera la sucesión  $\{(\theta^n, \phi^n)\}$  como una cadena de Markov (Apéndice A.2).

En la figura 2 y 3 se observan los valores de  $\theta$  y  $\phi$  respectivamente según el número de iteraciones (Apéndice B.2 y B.3).



**Figure 2:** Valores de  $\theta$  según su número de iteración.



**Figure 3:** Valores de  $\phi$  según su número de iteración.

## 4 Ejercicio 4

Removiendo las 500 primeras iteraciones calcule las medias y las varianzas muestrales de  $\theta | \vec{x}$  y  $\sigma^2 | \vec{x}$ .

Respuesta:

Luego de eliminar las 500 primeras iteraciones (Apéndice A.3), se obtienen los siguientes valores para la media y la varianza de  $\theta$  y  $\phi$  (Apéndice A.3).

Variable	Media	Varianza
$\theta$	5.005	0.039
$\phi$	0.536	0.011

Los valores esperados de  $\theta$  y  $\phi$  son 5 y 0.5 respectivamente, dado que  $X \sim N(\theta = 5, \phi^{-1} = 2)$ . En nuestro caso, notamos que la media de  $\theta$  y  $\phi$  están muy cercanas a las cantidades esperadas. Además, las variables no poseen mucha variabilidad.


## 5 Ejercicio 5

Construir los histogramas para  $\theta | + \vec{x}$  y  $\sigma^2 | + \vec{x}$  usando los últimos 500 datos.

Respuesta:


En la figura 4 y 5 se tienen los histogramas de  $\theta$  y  $\phi$  respectivamente (Apéndice B.4 y B.5), en donde se marca con una recta azul la media de la variable. Notamos que  $\theta$  se acerca bastante a una normal, mientras que  $\phi$  tiene forma de distribución normal con una leve asimetría positiva.

Simulación de distribución condicional a posteriori de Theta usando las últimas 500 repeticiones.



**Figure 4:** Distribución a posteriori de Theta.

Simulación de distribución condicional a posteriori de  $\Phi$  usando las últimas 500 repeticiones.



**Figure 5:** Distribución a posteriori de  $\Phi$ .




## 6 Ejercicio 6

Generar el histograma de la distribución conjunta  $\pi(\theta, \phi | \vec{x})$  (3D). Compare esto con un histograma generado por el método aceptación/rechazo.


Respuesta:

En la figura 8 se realiza el histograma de la distribución conjunta (Apéndice B.6), notamos una gran concentración de datos cercano a la media de  $\theta$  (graficado en el eje x), específicamente entre 4.80 y 5.28. Asimismo, los valores de  $\phi$  (graficados en el eje Y) se concentran cercano a 0.5. El par con mayor cantidad de datos se encuentra en los intervalos  $\theta = [4.93, 4.98]$  y  $\phi = [0.5, 0.53]$ . Estos resultados son los esperados luego de visualizar el histograma de  $\theta$  y  $\phi$  calculadas con el método de Gibbs sampling.



**Figure 6:** Distribución conjunta mediante el método Gibbs sampling

Luego, en la figura 9 se realiza el histograma mediante el método aceptación/rechazo (Apéndice A.4 y B.7). Notamos que  $\theta$  (representado en el eje x) tiene valores en todo su dominio, concentrando un gran cantidad cercano a su media. Por otro lado,  $\phi$  (representado en el eje Y) no posee datos en algunos intervalos, como  $[0.51, 0.58]$  y la frecuencia de datos es mayor en valores mayor a 0.61, lo cual indica que el método de aceptación/rechazo genera mas cantidad de datos en valores mas grandes que el método Gibbs sampling.



**Figure 7:** Distribución conjunta mediante el método aceptación/rechazo.

## 7 Apéndice A

### Simulación de distribuciones

#### Apéndice A.1

```
set.seed(2)
n=50
theta = 5
phi1 = 2
SIM50 = data.frame('simulation' = rnorm(n,
                                         theta,
                                         sd = sqrt(phi1)))
```

#### Apéndice A.2

```
# numero de muestras
S <- 1000

# matriz para almacenar las muestras
PHI <- matrix(data = NA, nrow = S, ncol = 2)
# ALGORITMO (muestreador de Gibbs)
# 1. inicializar la cadena
#     valor inicial: simular de la previa
#     solo es necesario alguno de los valores
set.seed(1)
phi <- c( rnorm(1, mu0, sd = sqrt(t20)), rgamma(1, nu0/2, s20/2) )
PHI[1,] <- phi

# 2. simular iterativamente de las distribuciones condicionales completas
set.seed(1)
for(s in 2:S) {
  # 2.1 actualizar el valor de theta
  t2n <- 1/( (t20**(-1)) + n*phi[2] )
  mun <- (n*phi[2]*mean(SIM50$simulation)) / (t20**(-1) + n*phi[2])
  phi[1] <- rnorm( 1, mun, sd = sqrt(t2n) )
  # 2.2 actualizar el valor de sigma^2
  nun <- nu0+n
  s2n <- s20 + (n-1)*var(SIM50$simulation) + n*(phi[1] - mean(SIM50$simulation))^2
  phi[2] <- rgamma(1, nun/2, s2n/2)
  # 2.3 almacenar
  PHI[s,] <- phi
}
```

#### Apéndice A.3

```
sub_phi = data.frame('post_theta' = PHI[501:1000,1],
                     'post_sigma' = PHI[501:1000,2])
sub_phi
```

```
# Theta
mean(sub_phi$post_theta)
var(sub_phi$post_theta)
```

```
# PHI
mean(sub_phi$post_sigma)
var(sub_phi$post_sigma)
```

#### Apéndice A.4

```
set.seed(2)
rep = 500
PHI <- matrix(data = NA, nrow = rep, ncol = 2)
phi <- c( rnorm(1, mu0, sd = sqrt(t20)), rgamma(1, nu0/2, s20/2) )
PHI[1,] <- phi

for(s in 2:rep) {
  # 2.1 actualizar el valor de theta
  t2n <- 1/( (t20**(-1)) + n*phi[2] )
  mun <- (n*phi[2]*mean(SIM50$simulation)) / (t20**(-1) + n*phi[2])
  phi[1] <- rnorm( 1, mun, sd = sqrt(t2n) )
  alpha = dnorm(phi[1], mean=5, sd=sqrt(2)) / dnorm(PHI[s-1,1], mean=5, sd=sqrt(2))

  if (runif(1) < alpha) {
    PHI[s, 1] = phi[1]}

  else{
    PHI[s] <- PHI[s - 1, 1]}

  #2.2 actualizar el valor de sigma^2

  nun <- nu0+n
  s2n <- s20 + (n-1)*var(SIM50$simulation) + n*(phi[1] - mean(SIM50$simulation))^2
  phi[2] <- rgamma(1, nun/2, s2n/2)
  alpha = dgamma(phi[2], shape = nun/2, scale = s2n/2) / dgamma(PHI[s-1,2], shape = nun/2, scale = s2n/2)

  # 2.3 almacenar
  if(runif(1) < alpha){
    PHI[s, 2] <- phi[2]}
  else{
    PHI[s, 2] <- PHI[s - 1, 2]}
}
```

## 8 Apéndice B

### Gráficos

#### Apéndice B.1

```
ggplot(SIM50, aes(x=simulation)) +  
  geom_histogram(aes(y=..density..),  
                 colour=1,  
                 fill="white",  
                 bins = 11)+  
  geom_density(lwd = 1,  
               alpha=.15,  
               fill="#FF6666") +  
  geom_vline(aes(xintercept=mean(simulation)),  
             color="blue", size=1) +  
  xlab("X") +  
  ylab("Probabilidad")+  
  ggtitle('Simulaci n desde una distribuci n N(5, 2)') +  
  theme(text = element_text(size = 20))
```

#### Apéndice B.2

```
plot(PHI[2:1000,1], type="l", ylab="Theta", xlab="Iteration")
```

#### Apéndice B.3

```
plot(PHI[,2], type="l", ylab="Phi", xlab="Iteration")
```

#### Apéndice B.4

```
ggplot(sub_phi, aes(x=post_theta)) +  
  geom_histogram(aes(y=..density..),  
                 colour=1,  
                 fill="white",  
                 bins = 15)+  
  geom_density(lwd = 1,  
               alpha=.15,  
               fill="#FF6666") +  
  geom_vline(aes(xintercept=mean(post_theta)),  
             color="blue", size=1) +  
  xlab("Theta") +  
  ylab("Densidad")+  
  ggtitle('Simulaci n de distribuci n condicional a posteriorir de Th  
  theme(text = element_text(size = 20))
```

#### Apéndice B.5

```

ggplot(sub_phi, aes(x=post_sigma)) +
  geom_histogram(aes(y=..density..),
                 colour=1,
                 fill="white",
                 bins = 15)+
  geom_density(lwd = 1,
               alpha=.15,
               fill="#FF6666") +
  geom_vline(aes(xintercept=mean(post_sigma)),
             color="blue", size=1) +
  xlab("Phi") +
  ylab("Densidad")+
  ggtitle('Simulaci n de distribuci n condicional a posteriorir de Ph
  theme(text = element_text(size = 20))

```

## Apéndice B.6

```

fig <- plot_ly(z = ~z) %>% add_surface(
  contours = list(
    z = list(
      show=TRUE,
      usecolormap = TRUE,
      highlightcolor="#ff0000",
      project=list(z=TRUE)
    )
  )
)
fig <- fig %>% layout(
  scene = list(camera=list(eye = list(x=1.87, y=0.88, z=-0.64)),
               xaxis = list(ticketmode = 'array',
                             ticktext = seq(4.28, 5.61, 0.05),
                             tickvals = 0:24,
                             range = c(0,24)),

               yaxis = list(ticketmode = 'array',
                             ticktext = round(seq(0.283,0.966, 0.027), 2),
                             tickvals = 0:24,
                             range = c(0,24))
               )
)
fig

```

##Generar las muestras mediante aceptacion / rechazo

## Apéndice B.7

```

fig <- plot_ly(z = ~z) %>% add_surface(
  contours = list(
    z = list(
      show=TRUE,
      usecolormap = TRUE,
      highlightcolor="#ff0000",
      project=list(z=TRUE)
    )
  )
)
fig <- fig %>% layout(
  scene = list(camera=list(eye = list(x=1.87, y=0.88, z=-0.64)),
    xaxis = list(ticketmode = 'array',
      ticktext = seq(4.28, 5.61, 0.05),
      tickvals = 0:24,
      range = c(0,24)),

    yaxis = list(ticketmode = 'array',
      ticktext = round(seq(0.283,0.966, 0.027), 2),
      tickvals = 0:24,
      range = c(0,24))
  )
)

```